Voice of Customer Intelligence com RAG

Transformando Avaliações de E-Commerce em Conhecimento Acessível e Rastreável

Fiap Pós
AI Scientist 2026
Fase 4

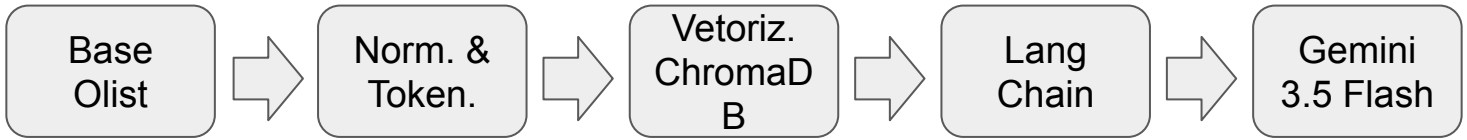
Ricardo Sallin
RM 372803

O problema de negócio

- **Cenário de Dados:** base de **~100 mil pedidos** da Olist com dezenas de milhares de comentários textuais não estruturados
- **Gargalo Operacional:** Análise manual demorada e pouco escalável
- **Objetivo Estratégico:** Realizar perguntas em linguagem natural sobre problemas de entrega, qualidade e atendimento, obtendo **respostas imediatas** e sustentadas por **evidências reais**

Arquitetura da Solução (Agentic Closed-Domain RAG)

- Arquitetura Fechada: Foco exclusivo no domínio de dados da Olist para evitar alucinações e contaminação com dados externos
- Fluxo do Pipeline:
  - Ingestão & Limpeza NLP: Consolidação e normalização dos textos
  - Indexação Vetorial: Armazenamento semântico no ChromaDB
  - Agente Orquestrador: LangChain seleciona as ferramentas adequadas
  - Geração Fundamentada: Síntese de respostas com Gemini 3.5 Flash Lite



Engenharia de Dados & Pré-processamento NLP

- Tratamento & Filtros: Remoção de avaliações sem texto (onde 86% eram notas 4-5) para concentrar o modelo em **42 mil reviews com conteúdo analítico**
- Enriquecimento Relacional: Merge entre dados de pedidos, itens e produtos para gerar metadados e permitir perguntas com filtros
- Pipeline de Limpeza Modular:
  - Normalização em minúsculas e tratamento de caracteres
  - Expansão de contrações informais de internet ("vc", "tb", "pq")
  - Remoção de stopwords e lematização com spaCy (`pt_core_news_lg`)

Base de Conhecimento Vetorial

- Banco Vetorial Persistente: Uso do ChromaDB armazenado em disco para buscas por similaridade de alta performance
- Embeddings Densos: Utilização do modelo **`gemini-embedding-001`** para mapeamento das intenções semânticas dos clientes
- Injeção de metadados (nota, categoria, flags de avaliação positiva e atraso) em cada documento
- Suporta filtros específicos nas consultas, como "problemas em avaliações com nota baixa"



Agente Controlador & Travas de Segurança (Guardrails)



- LangChain: ferramenta de recuperação dedicada via `create_retriever_tool`
- Sem Busca Web: Desativação deliberada de ferramentas de busca na internet para manter a resposta restrita ao acervo interno
- Guardrails (declarar limitação de dados):
  - Empresas concorrentes (ex: Amazon)
  - Épocas ou quebras fora da base (ex: WhatsApp em 2026)

Validação dos Testes & Rastreabilidade

- Bateria de Testes Práticos: Execução automatizada para investigar atrasos de entrega, elogios, produtos com defeito e insatisfação
- Rastreabilidade de Insights: Todas as respostas geradas pelo agente apresentam a lista com as evidências reais recuperadas
- Segurança Comprovada: Testes de fora de escopo resultaram na recusa adequada pelo modelo, cumprindo os requisitos de governança do projeto

Entregáveis do projeto & Próximos Passos

- Repositório no GitHub: código-fonte completo e arquivo README.md detalhando decisões técnicas
- Vídeo de Apresentação Executiva descrevendo a arquitetura RAG e execução em tempo real
- Conclusão: Solução pronta para escalar o entendimento do cliente com baixo custo computacional e alta fidelidade aos dados reais



Obrigado